


Copilot Meta-Prompting

Copilot Chat 프롬프트를 가로채 자동 정제하는 메타프롬프팅 시스템

@refine — 거친 한 줄 질문을, 검증된 고품질 프롬프트로



01 배경

왜 메타프롬프팅인가

문제

짧고 모호한 프롬프트(“정렬 코드 짜줘”)
→ 빛나간 답 → 다시 묻는 비효율
→ 토큰·시간 낭비.

핵심 통찰

정답은 “더 비싼 모델”이 아니라
“더 좋은 프롬프트”.
소형 모델도 잘 설계된 프롬프트면 고품질 → 토큰 절감.

해법

입력과 LLM 사이에 ‘정제 계층’을 끼워 넣되,
미리보기·승인으로 가로막지 않는다.
— “끼어들되 가로막지 않는다”


02 아키텍처

전체 구조 — FE 확장 ↔ BE 파이프라인



03 파이프라인

정제는 어떻게 일어나는가 — 4단계



@refine UX — 5가지 승인 선택지

✓ 전송	정제본 자동 전송	기록
✎ 수정	정제본을 입력창에 채워 편집	
↺ 다시 정제	동일 원본으로 재정제	
→ 원본 전송	정제 없이 원본 전송	
✕ 취소	@refine 원본을 입력창에 복원	

설계 불변식

fail-open	명시 호출만	승인 게이트	의존성 0(FE)
JSONL 동결	데이터 보존		

기술 스택

FRONTEND	BACKEND	AI / INFRA
- VS Code Extension API - Chat Participant API - WebviewController + CSP - Node http/https/fs - JSONL · @vscode/vsce - 런타임 의존성 0	- FastAPI · uvicorn - requests - ChromaDB 1.5 - OpenAI SDK 2.44 - scikit-learn (viz) - 버전 락 고정	- vLLM 0.19.1 - Qwen3.6-35B (AWQ) - Qwen3-Embedding-8B - Qwen3-Reranker-4B - OpenAI 호환 /v1/* - 로컬 GPU / RunPod

결과

요구사항 분석 → 설계 → 구현 → 테스트 → 실행까지 전 사이클 완결

7 / 30

모듈 / 요구사항 구현

25 / 25

단위 테스트 통과

651 · 4096

템플릿 · 임베딩 차원

0

FE 런타임 의존성